

Mínimos Quadrados, ARX, ARMAX e OE

Eduardo Henrique Basilio de Carvalho

15 de setembro de 2025

Questão 1

Seja

$$y = 1.5x^2 + 0.7x - 2 \quad (1)$$

a

A figura 1 apresenta a curva para $x \in [-6, 6]$.




Figura 1: Curva de $y = 1.5x^2 + 0.7x - 2$

b

A figura 2 apresenta a curva com ruído uniforme com amplitude $\pm 0.1\max(|y|)$.




Figura 2: Curva de $y = 1.5x^2 + 0.7x - 2$ com ruído

c

A equação de regressão é $y = \theta_2 x^2 + \theta_1 x + \theta_0$.

d

A matriz de regressores é

$$A = \begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ \vdots & \vdots & \vdots \\ x_N^2 & x_N & 1 \end{bmatrix} \quad (2)$$

e

Os coeficientes estimados por mínimos quadrados são $\theta_0 = 1.52$, $\theta_1 = 0.47$ e $\theta_2 = -2.59$. A figura 3 compara a curva de referência com a obtida a partir dos parâmetros estimados.

f


Com 1000 pontos, a curva ajustada é $y = 1.51x^2 + 0.68x - 2.12$. A figura 4 compara a curva de referência com a obtida a partir dos parâmetros estimados.

Com o aumento substancial de redundância, a estimação de parâmetros é mais robusta.

g


Sob a soma de ruído com amplitude $0.1\Delta x$ na entrada, os coeficientes estimados são $\theta_0 = 1.25$, $\theta_1 = 0.66$ e $\theta_2 = 0.58$. A figura 5 apresenta a curva correspondente.

Mesmo com a elevada quantidade de regressores, o ruído na entrada prejudica significativamente a estimação dos parâmetros.




H

Figura 3: Curva de referência vs curva ajustada



H

Figura 4: Curva de referência vs curva ajustada para $N = 1000$



H

Figura 5: Curva de referência vs curva ajustada sob ruído na entrada (N=1000)

Questão 2

a, b, c, d

A figura 6 apresenta os sistemas simulados para uma mesma entrada.




Figura 6: Sistemas de referência

Questão 3

ARX

Dado

$$A(z)y[k] = B(z)u[k] + e[k]$$

com dois atrasos em $A(z)$ e $B(z)$,

$$\begin{aligned} y[k] + a_1 y[k-1] + a_2 y[k-2] &= b_1 u[k-1] + b_2 u[k-2] + e[k] \\ y[k] &= -a_1 y[k-1] - a_2 y[k-2] + b_1 u[k-1] + b_2 u[k-2] + e[k] \end{aligned}$$

Seja

$$\begin{aligned} Y &= \begin{bmatrix} y[2] \\ y[3] \\ y[4] \\ \vdots \\ y[N-1] \end{bmatrix} \\ \Phi &= \begin{bmatrix} y[1] & y[0] & u[1] & u[0] \\ y[2] & y[1] & u[2] & u[1] \\ y[3] & y[2] & u[3] & u[2] \\ \vdots & \vdots & \vdots & \vdots \\ y[N-2] & y[N-3] & u[N-2] & u[N-3] \end{bmatrix} \\ \theta &= \begin{bmatrix} -a_1 \\ -a_2 \\ b_1 \\ b_2 \end{bmatrix} \\ E &= \begin{bmatrix} e[2] \\ e[3] \\ e[4] \\ \vdots \\ e[N-1] \end{bmatrix} \end{aligned}$$

,

então

$$Y = \Phi\theta + E$$

e a estimativa por mínimos quadrados é

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

A figura 7 compara a curva de referência com a curva ajustada por ARX. Ambas as respostas são computadas sobre um novo vetor de entrada, com as mesmas características do usado para a estimação, mas em outra realização, a fim de confirmar generalização.




Figura 7: Curva de referência vs curva ajustada por ARX

ARMAX

Dado

$$A(z)y[k] = B(z)u[k] + C(z)e[k]$$

com dois atrasos em $A(z)$, $B(z)$ e $C(z)$,

$$\begin{aligned} y[k] + a_1y[k-1] + a_2y[k-2] &= b_1u[k-1] + b_2u[k-2] + e[k] + c_1e[k-1] + c_2e[k-2] \\ y[k] &= -a_1y[k-1] - a_2y[k-2] + b_1u[k-1] + b_2u[k-2] + e[k] + c_1e[k-1] + c_2e[k-2] \end{aligned}$$

A construção

$$Y = \Phi\theta$$

com

$$\begin{aligned} Y &= \begin{bmatrix} y[2] \\ y[3] \\ y[4] \\ \vdots \\ y[N-1] \end{bmatrix} \\ \Phi &= \begin{bmatrix} y[1] & y[0] & u[1] & u[0] & e[1] & e[0] \\ y[2] & y[1] & u[2] & u[1] & e[2] & e[1] \\ y[3] & y[2] & u[3] & u[2] & e[3] & e[2] \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ y[N-2] & y[N-3] & u[N-2] & u[N-3] & e[N-2] & e[N-3] \end{bmatrix} \\ \theta &= \begin{bmatrix} -a_1 \\ -a_2 \\ b_1 \\ b_2 \\ c_1 \\ c_2 \end{bmatrix} \end{aligned}$$

é válida, mas não pode ser usada para estimar θ por mínimos quadrados, pois $e[k]$ não é conhecido. Neste caso, o método *quadrados mínimos estendido* é uma solução. O algoritmo é:

1. Estime um modelo ARX sobre os dados; 2. Calcule os resíduos do modelo ARX estimado; 3. Use os resíduos como uma estimativa para $e[k]$ e construa a matriz de regressores; 4. Estime o modelo ARMAX usando mínimos quadrados; 5. Calcule os resíduos do modelo ARMAX estimado; 6. Repita os passos 3 a 5 até convergência.

A figura 8 compara a curva de referência com a curva ajustada por ARMAX. As condições para o vetor de validação são as mesmas da validação do ARX.




Figura 8: Curva de referência vs curva ajustada por ARMAX

OE

Dado

$$F(z)y[k] = B(z)u[k] + F(z)e[k]$$

com dois atrasos em $F(z)$ e $B(z)$,

$$\begin{aligned} y[k] + f_1y[k-1] + f_2y[k-2] &= b_0u[k] + b_1u[k-1] + b_2u[k-2] + f_0e[k] + f_1e[k-1] + f_2e[k-2] \\ y[k] &= -f_1y[k-1] - f_2y[k-2] + b_0u[k] + b_1u[k-1] + b_2u[k-2] + f_0e[k] + f_1e[k-1] + f_2e[k-2] \end{aligned}$$

Assim como para ARMAX, a separação entre saída, regressores e parâmetros constrói um sistema não linear nos parâmetros. Porém, neste caso, não é possível partir de uma estimativa inicial que ignore os erros de medição, já que assumir $F(z) = 1$ desconsidera, também, a dinâmica do sistema. Resta, então, resolver por otimização não linear. Um algoritmo candidato é:

1. Estime F como A em um modelo ARX (chute inicial); 2. Compute B correspondente, dado que y, u e F são conhecidos, assim como e, assumido zero; 3. Calcule os resíduos do modelo OE estimado; 4. Compute um novo F, minimizando os resíduos; 5. Repita os passos 2 a 4 até convergência.

A figura 9 compara a curva de referência com a curva ajustada por OE. As condições para o vetor de validação são as mesmas da validação do ARX.




Figura 9: Curva de referência vs curva ajustada por OE

Comparação

ARX

A identificação foi simples e resultou em um modelo com boa performance na validação. Isso decorre de ser um modelo totalmente linear nos parâmetros desde o princípio, o que permite o uso direto de mínimos quadrados.

ARMAX

A identificação ainda é consideravelmente simples, dado que estimar os erros é um problema de regressão linear. Assim como o ruído filtrado é a diferença entre a saída medida e a resposta da função geradora, os resíduos são a diferença entre a saída medida e a resposta do modelo estimado. Por isso, este é um estimador adequado para aquele. A performance decorrente dessa consideração, no entanto, foi inferior à dos demais casos.

OE

Descartada a possibilidade de regressão linear, a identificação é mais complexa. Tal complexidade, entretanto, é concentrada na seleção de um novo candidato para F , passo que pode ser delegado ao módulo SciPy. Com esta ferramenta mais robusta, a performance do modelo foi, visualmente, tão boa quanto a do ARX.

Questão 4

Seja $J_{MQ} = (y - \Psi\Theta)^T(y - \Psi\Theta)$ e Ψ não singular.

$$\begin{aligned} J_{\text{reg}} &= \frac{1}{2} [(y - \Psi\Theta)^T(y - \Psi\Theta)] + \frac{1}{2} \lambda \Theta^T \Theta \\ J_{\text{reg}} &= \frac{1}{2} (y^T y - 2y^T \Psi\Theta + \Theta^T \Psi^T \Psi\Theta) + \frac{1}{2} \lambda \Theta^T \Theta \\ \nabla_{\Theta} J_{\text{reg}} &= -\Psi^T y + (\Psi^T \Psi)\Theta + \lambda \Theta \end{aligned}$$

Para ponto crítico,

$$\begin{aligned}
0 &= -\Psi^T y + (\Psi^T \Psi) \Theta + \lambda \Theta \\
(\Psi^T \Psi + \lambda I) \Theta &= \Psi^T y \\
\hat{\Theta}_{\text{reg}} &= (\Psi^T \Psi + \lambda I)^{-1} \Psi^T y
\end{aligned}$$

Para mínimo,

$$\nabla_{\Theta}^2 J_{\text{reg}} = \Psi^T \Psi + \lambda I > 0$$

O que é garantido para $\lambda > 0$.