

Estimação Recursiva de Parâmetros

Eduardo Henrique Basilio de Carvalho

20 de outubro de 2025

Introdução

Este relatório detalha a implementação, comparação e análise de um conjunto de algoritmos de estimação recursiva de parâmetros. Os exercícios abordam desde a estimação de parâmetros em sistemas lineares com parâmetros constantes (LTI) até o rastreamento de parâmetros variantes no tempo e a aplicação dos métodos em dados experimentais de um sistema térmico. O objetivo principal é validar experimentalmente as propriedades teóricas dos estimadores, como convergência, viés e variância, e avaliar seu desempenho sob condições ideais e não ideais, como a presença de ruído com média não-nula ou ruído colorido.

Exercício 1: Fundamentos dos Estimadores Recursivos

Neste exercício, foi investigado o desempenho de quatro famílias de estimadores recursivos na identificação de um sistema ARX de primeira ordem com parâmetros constantes.

1.a) Estimador Recursivo Não Polarizado

Análise dos Resultados

Os resultados dos histogramas mostram uma diferença marcante de desempenho entre os estimadores do tipo Gradiente e Gauss-Newton. O método de Gradiente, com um ganho fixo $\bar{K}$ bem ajustado, apresenta estimativas com um viés baixo (especialmente para b_1) e uma variância contida, resultando em uma distribuição concentrada em torno do valor verdadeiro. Em contraste, o método de Gauss-Newton, cuja atualização depende do termo $(\Psi_k^T \Psi_k)^{-1}$, exibe uma variância extremamente alta. Isso sugere uma sensibilidade numérica: quando o vetor de regressores Ψ_k tem uma norma pequena, a inversão amplifica drasticamente o ruído, gerando estimativas espúrias (**outliers**) que deslocam a média e alargam a distribuição. A implicação prática é que, embora teoricamente robusto, o método de Gauss-Newton simplificado é numericamente instável sem uma normalização adequada, como a proposta na equação 13 do material de aula.




Figura 1: Histogramas para os estimadores tipo Gradiente e Gauss-Newton.

1.b) Estimador de Aproximação Estocástica

Análise dos Resultados

A introdução do termo de decaimento $k^{-\alpha}$ nos ganhos, característico da aproximação estocástica, teve um efeito estabilizador notável. Para ambos os métodos, a variância foi drasticamente reduzida. Isso ocorre porque, à medida que k aumenta, o ganho de atualização diminui, tornando o estimador menos suscetível ao ruído em amostras futuras, favorecendo a convergência. Para o método de Gauss-Newton, essa redução de ganho mitigou a instabilidade numérica, resultando em uma forte redução do viés. Contudo, para o método de Gradiente, o viés aumentou. Uma hipótese é que o ganho decaiu muito rapidamente, fazendo com que o algoritmo "congele" em uma estimativa sub-ótima antes de alcançar o valor verdadeiro, um clássico compromisso entre velocidade de convergência e precisão final.




Figura 2: Histogramas para os estimadores de aproximação estocástica.

1.c) Estimador de Mínima Covariância

Análise dos Resultados

O estimador de Mínima Covariância, que é uma formulação do Filtro de Kalman para estimação de parâmetros, apresentou um desempenho exemplar. Ao utilizar o conhecimento da covariância do ruído (R) e propagar a matriz de covariância da estimativa (P_k), o algoritmo calcula um ganho ótimo a cada passo. O resultado, como visto nos histogramas, é uma estimativa com viés desprezível e variância mínima entre os métodos testados. Isso valida a teoria de que, quando o modelo do sistema e as estatísticas do ruído são conhecidas, este estimador é ótimo no sentido de minimizar a variância do erro de estimação.




Figura 3: Histogramas para o estimador de mínima covariância.

1.d) Mínimos Quadrados Recursivo (MQR)

Análise dos Resultados

O MQR demonstrou um desempenho praticamente idêntico ao do estimador de Mínima Covariância, com viés desprezível e variância muito baixa. A principal diferença teórica é que o MQR minimiza o somatório dos erros quadráticos, enquanto a Mínima Covariância minimiza a variância da estimativa final. Na prática, para ruído branco com média zero, os dois convergem para soluções muito semelhantes. A robustez e a eficiência do MQR, sem a necessidade de conhecer a covariância do ruído **a priori**, fazem dele um dos métodos mais populares e utilizados em aplicações práticas.




Figura 4: Histogramas para o estimador MQR.

1.e) Comparação Geral e Impacto de N

Análise dos Resultados

A análise assintótica confirma as propriedades teóricas dos estimadores. Para os métodos consistentes (MQR, Mínima Covariância, e as variantes de Gradiente), o viés e a variância tendem a diminuir à medida que mais amostras (N) são utilizadas, pois mais informação é agregada para refinar a estimativa. Notavelmente, MQR e Mínima Covariância exibem uma taxa de convergência superior, com a variância caindo de forma mais acentuada. O comportamento da variância do método de Gradiente (que aumenta e depois estabiliza) é interessante; uma hipótese é que o ganho fixo $\bar{K}$ continua a injetar uma quantidade constante de incerteza a cada passo (termo

$K_k R K_k^T$ na equação 16), o que limita a redução da variância final, diferentemente dos métodos cujo ganho diminui com o tempo. O comportamento errático de Gauss-Newton reforça sua instabilidade.




Figura 5: Evolução do viés e variância em função do número de amostras (N).

1.f) Trajetória dos Parâmetros

Análise dos Resultados

A evolução temporal das estimativas para uma única realização de ruído ilustra a dinâmica de cada algoritmo. O MQR e a Mínima Covariância convergem suave e rapidamente para os valores verdadeiros, demonstrando sua eficiência. A Aproximação Estocástica do Gradiente mostra uma convergência muito mais lenta, porém estável e com baixo ruído no estado estacionário. Em contraste, o Gradiente com ganho fixo converge rápido, mas a estimativa permanece ruidosa, oscilando em torno do valor real. Os métodos baseados em Gauss-Newton mostram picos de alta amplitude, evidenciando a instabilidade numérica já discutida. A trajetória de MQR e Mínima Covariância é o comportamento desejado para a identificação de sistemas LTI.

Evolução Temporal dos Parâmetros Estimados




Figura 6: Evolução temporal das estimativas de parâmetros para cada método.

Exercício 2: Parâmetros Variantes no Tempo

Este exercício avaliou a capacidade de rastrear parâmetros que mudam com o tempo.

2.a) Efeito do Fator de Esquecimento (λ)

Análise dos Resultados

O fator de esquecimento λ no MQR-FF ajusta a "memória" do estimador. Valores de λ próximos de 1 (e.g., 0.999) atribuem um peso maior aos dados passados, resultando em uma estimativa suave, mas com um atraso significativo no rastreamento (viés dinâmico). Valores menores de λ (e.g., 0.9) "esquecem" o passado rapidamente, tornando o estimador mais ágil para seguir as variações, porém muito mais sensível ao ruído. O valor $\lambda = 0.95$ representa um bom compromisso, conseguindo acompanhar a tendência dos parâmetros reais sem amplificar excessivamente o ruído. A escolha de λ é, portanto, um compromisso fundamental entre a capacidade de rastreamento e a rejeição a ruído.




Figura 7: Rastreamento de parâmetros variantes no tempo para diferentes valores de λ .

2.b) Efeito da Persistência de Excitação

Análise dos Resultados

A persistência de excitação é fundamental para a estimação de parâmetros, pois garante que o sistema seja "sondado" em diferentes direções, fornecendo informação suficiente para identificar todos os parâmetros. Ao manter a entrada constante por períodos mais longos (**hold**), a informação contida no vetor de regressores Ψ_k torna-se pobre e, em alguns instantes, a matriz $\Psi_k^T \Psi_k$ pode se tornar mal condicionada. Os resultados mostram claramente a degradação do desempenho: quanto maior o período de **hold**, maior o atraso e o ruído nas estimativas. Isso ocorre porque o estimador não recebe "informação nova" suficiente para atualizar os parâmetros corretamente, fazendo com que a matriz de covariância P_k cresça e o rastreamento se deteriore.

Efeito da Persistencia de Excitacao no Rastreamento de Parametros




Figura 8: Efeito da persistência de excitação na qualidade do rastreamento.

Exercício 3: Condições Não Ideais

Este exercício testou a robustez dos estimadores quando as premissas sobre o ruído são violadas.

3.a) Ruído com Média Não-Nula

Análise dos Resultados

Todos os estimadores implementados partem da premissa de que o ruído $\eta(k)$ tem média zero. Quando essa premissa é violada, o termo de ruído se comporta como um **offset** persistente, que é erroneamente incorporado na estimação dos parâmetros. Como resultado, os histogramas mostram que a média das estimativas de a_1 é significativamente deslocada, introduzindo um viés que não desaparece mesmo com muitas amostras. Isso demonstra uma limitação fundamental desses estimadores: eles não conseguem distinguir entre a dinâmica do processo e um distúrbio constante na saída. Para resolver isso, seria necessário aumentar o modelo, por exemplo, estimando um termo de **offset** adicional.




Figura 9: Efeito da média não-nula no MQR para parâmetros constantes.

3.b) Ruído Colorido

Análise dos Resultados

O ruído colorido, que possui correlação temporal, viola outra premissa central do MQR: a de que o erro de predição em um instante não está correlacionado com os regressores passados. Quando essa correlação existe, como no caso do ruído colorido, o MQR produz estimativas enviesadas. Os histogramas mostram claramente que a média das estimativas de a_1 está deslocada do valor verdadeiro. O viés é persistente e não é corrigido com o aumento do número de amostras. Para lidar com ruído colorido, seriam necessárias técnicas mais avançadas, como o método das Variáveis Instrumentais (IV) ou o Mínimos Quadrados Estendido (Extended Least Squares - ELS), que modelam explicitamente a dinâmica do ruído.




Figura 10: Efeito do ruído colorido no MQR para parâmetros constantes.

Exercício 4: Aplicação em Dados Reais

Neste exercício, os métodos foram aplicados para identificar um modelo para um sistema térmico real.

4.a) Pré-processamento dos Dados

Análise dos Resultados

O pré-processamento dos dados foi uma etapa fundamental. Sistemas térmicos possuem dinâmicas lentas, tornando-os suscetíveis a superamostragem. A remoção dos transitórios inicial e final garantiu que apenas dados em regime fossem utilizados para a identificação. A remoção da média focou o modelo na dinâmica de variação em torno do ponto de operação. Finalmente, a decimação reduziu a carga computacional e a correlação entre amostras consecutivas, o que é benéfico para os algoritmos de estimação. Os gráficos mostram a transformação de um sinal longo e com variações lentas em um sinal mais curto e adequado para a modelagem ARX.




Figura 11: Comparação dos sinais originais e processados.

4.b) Estimação com MQR Padrão

Análise dos Resultados

O MQR Padrão, ao ser aplicado aos dados da câmara térmica, produziu estimativas de parâmetros que convergem e se estabilizam. Isso sugere que um modelo LTI (Linear Time-Invariant) de ordem 4 é uma aproximação razoável para a dinâmica do sistema em torno do ponto de operação. A estabilização dos parâmetros indica que o algoritmo encontrou um conjunto de valores que minimiza o erro quadrático ao longo de todo o conjunto de dados.




Figura 12: Evolução dos parâmetros do modelo com MQR Padrão.

4.c) Estimador de Espaço de Estados (Filtro de Kalman)

Análise dos Resultados

O Filtro de Kalman, configurado para estimar parâmetros, permite modelar a incerteza não apenas na medição (R), mas também nos próprios parâmetros (Q). Ao usar uma matriz Q não nula, assume-se que os parâmetros podem variar ao longo do tempo (modelo de passeio aleatório). O resultado são trajetórias de parâmetros mais suaves em comparação com o MQR-FF, pois o filtro otimamente equilibra a informação nova com a predição do estado anterior. As variações suaves nos parâmetros de 'a' podem estar capturando a dinâmica real de como a eficiência de troca térmica muda com a temperatura ambiente, que, como mencionado no enunciado, variou durante o experimento.




Figura 13: Evolução dos parâmetros do modelo com Filtro de Kalman.

4.d) Estimação com MQR com Fator de Esquecimento

Análise dos Resultados

A utilização do MQR com Fator de Esquecimento (MQR-FF) assume explicitamente que os parâmetros do sistema não são constantes. O valor de $\lambda = 0.995$ confere ao estimador uma memória longa, permitindo que ele se adapte a variações lentas, o que é apropriado para um sistema térmico. As trajetórias dos parâmetros, embora ainda ruidosas, mostram variações consistentes que não estão presentes no MQR padrão. Uma hipótese plausível é que essas variações estão rastreando mudanças reais na dinâmica do sistema, causadas por fatores não modelados, como a variação da temperatura ambiente ao longo do longo período de coleta de dados. Isso demonstra a superioridade de um modelo adaptativo para sistemas que operam por longos períodos em condições variáveis.

Evolucao dos Parametros (MQR com Fator de Esquecimento, $\lambda=0.995$)




Figura 14: Evolução dos parâmetros com MQR com Fator de Esquecimento ($\lambda = 0.995$).

Conclusão Geral

Este estudo permitiu uma análise prática e comparativa de diversos estimadores recursivos. Para sistemas com parâmetros constantes e ruído branco, os estimadores de Mínima Covariância e MQR mostraram-se superiores, com rápida convergência e baixa variância. Para parâmetros variantes no tempo, o MQR com fator de esquecimento (MQR-FF) demonstrou ser eficaz, embora a escolha do fator λ seja um compromisso crucial entre agilidade e robustez ao ruído. Os exercícios também destacaram a importância das condições ideais: a presença de ruído com média não-nula ou colorido degrada o desempenho dos estimadores, introduzindo viés. Finalmente, a aplicação a dados reais de um sistema térmico mostrou que métodos adaptativos, como o Filtro de Kalman ou o MQR-FF, podem ser mais adequados para capturar a dinâmica de sistemas cujos parâmetros variam lentamente com o tempo devido a influências externas.